In [3]:

from sklearn import cross\_validation, datasets, metrics, neighbors from matplotlib.colors import ListedColormap import matplotlib.pyplot as plt import numpy as np

%matplotlib inline

/usr/local/lib/python2.7/dist-packages/sklearn/cross\_validation.py:44: DeprecationWarning: This module was deprecated in version 0.18 in favor of the model\_selection module into which all the refactored classes and functions are moved. Also note that the interface of the new CV iterators are different from that of this module. This module will be removed in 0.20.

"This module will be removed in 0.20.", DeprecationWarning)

## Метод к ближайших соседей

In [68]:

n samples = 200

In [69]:

 $classification\_problem = datasets.make\_classification(n\_samples=n\_samples,$ 

n\_features=2, n\_classes=4, n\_redundant=0, n\_clusters\_per\_class=1, random\_state=10)

In [36]:

In [37]:

def get\_meshgrid(data, step=.05, border=.5,):

x\_min, x\_max = data[:, 0].min() - border, data[:, 0].max() + border y\_min, y\_max = data[:, 1].min() - border, data[:, 1].max() + border

return np.meshgrid(np.arange(x\_min, x\_max, step), np.arange(y\_min, y\_max, step))

In [38]:

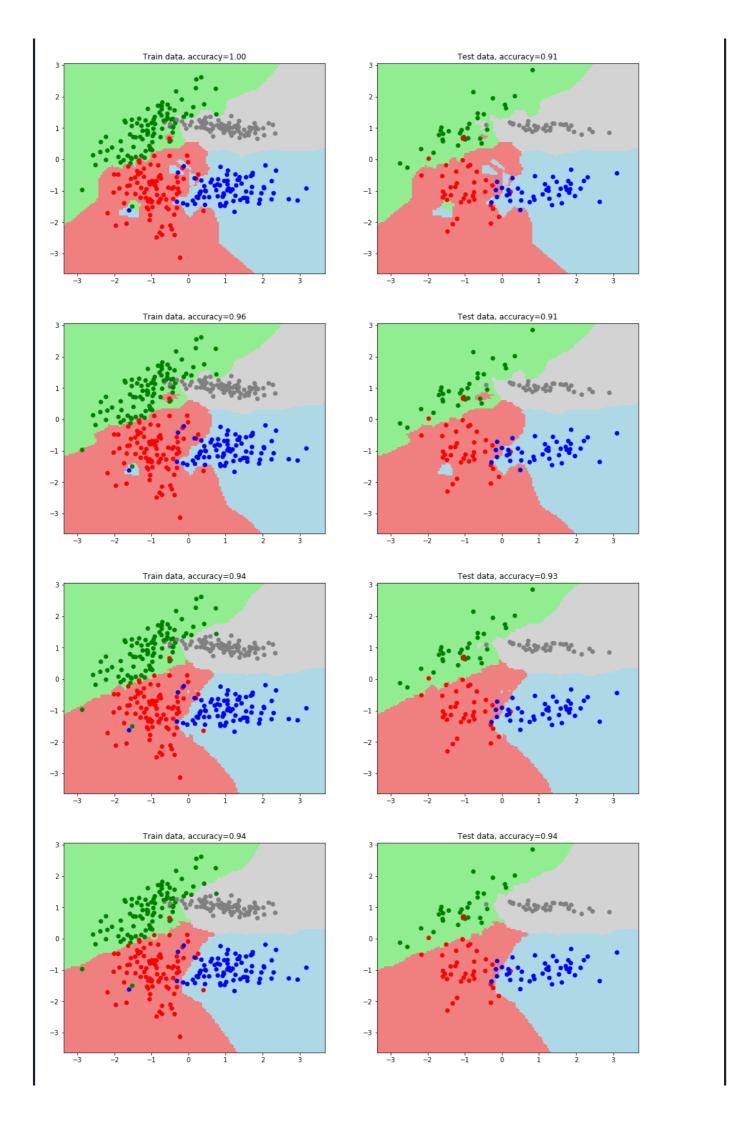
colors = ListedColormap(['red', 'blue', 'green', 'grey'])
light\_colors = ListedColormap(['lightcoral', 'lightblue', 'lightgreen', 'lightg

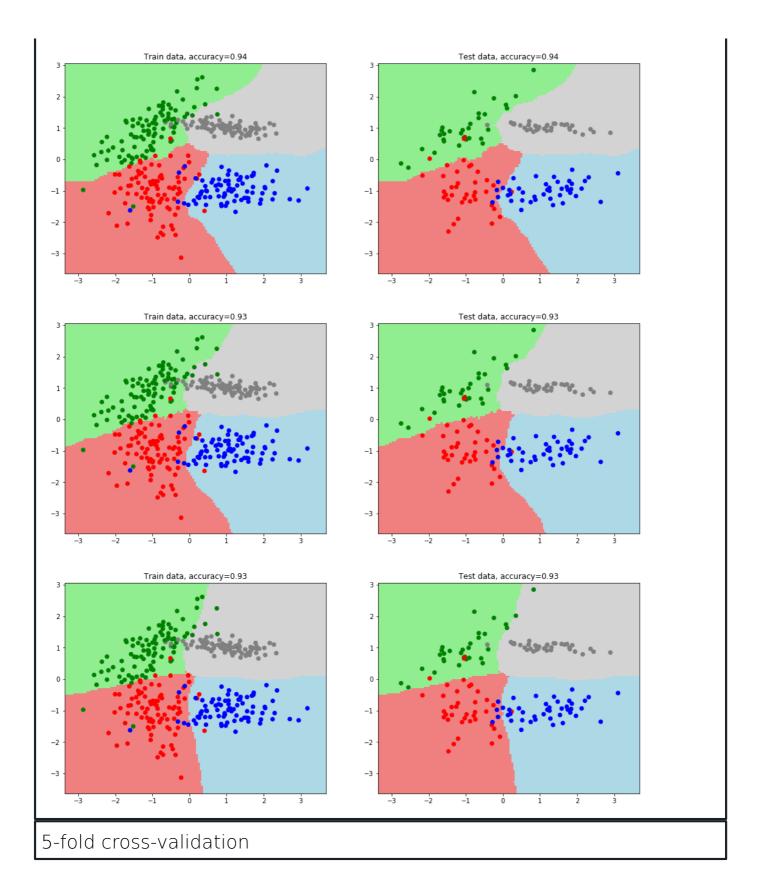
```
In [42]:
def plot_decision_surface(estimator, train_data, train_labels, test_data, test_labels):
   #fit model
   estimator.fit(train_data, train_labels)
   #set figure size
   plt.figure(figsize = (16, 6))
   #plot decision surface on the train data
   plt.subplot(1,2,1)
   xx, yy = get_meshgrid(train_data)
   mesh_predictions = np.array(estimator.predict(
      np.c_[xx.ravel(), yy.ravel()])).reshape(xx.shape)
   plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
   plt.scatter(train_data[:,0], train_data[:,1], c=train_labels, cmap=colors)
   plt.title('Train data, accuracy={:.2f}'.format(
      metrics.accuracy\_score(train\_labels,\ estimator.predict(train\_data))))
   #plot decision surface on the test data
   plt.subplot(1,2,2)
   plt.pcolormesh(xx, yy, mesh_predictions, cmap = light_colors)
   plt.scatter(test_data[:,0], test_data[:,1], c=test_labels, cmap=colors)
   plt.title('Test data, accuracy={:.2f}'.format(
      metrics.accuracy_score(test_labels, estimator.predict(test_data))))
```

In [43]:

neighb = [1, 2, 5, 7, 10, 20, 50]

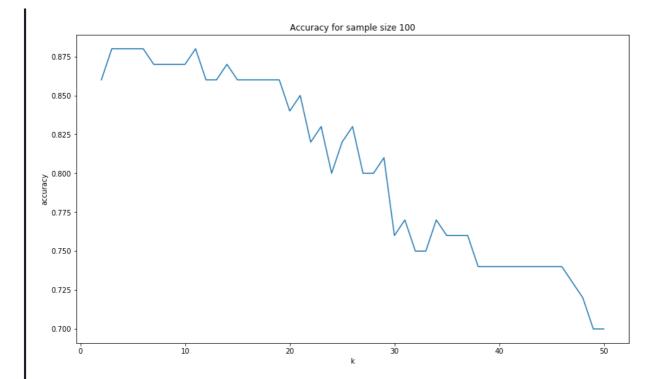
In [44]:	
for n in neighb:	
estimator = neighbors.KNeighborsClassifier(n_neighbors=n)	
plot_decision_surface(estimator, train_data, train_labels, test_data, test_labels)	
I	



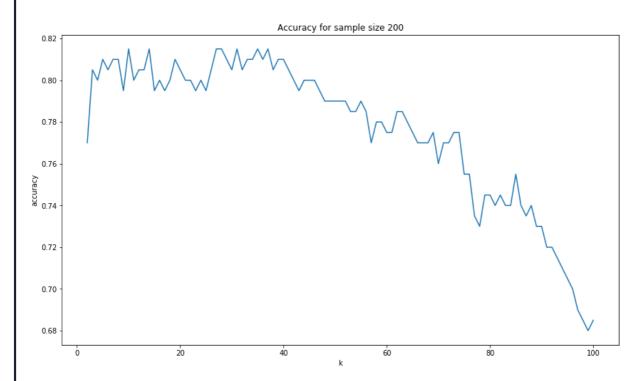


```
In [85]:
def get_accuracies(n_samples, k_max):
   accuracy = []
   for k in xrange(2, k_max+1):
      current\_acc = 0
      classification\_problem = datasets.make\_classification(n\_samples=n\_samples,
                                           n_features=2,
                                           n_classes=4, n_redundant=0,
                                           n_clusters_per_class=1,
                                           random_state=10)
      for train_indices, test_indices in cross_validation.KFold(n_samples,
                                                    n_folds=5,
                                                    shuffle=True,
                                                    random_state=10):
         train\_data = classification\_problem[0][train\_indices]
         train\_labels = classification\_problem \emph{[1]} [train\_indices]
         est = neighbors.KNeighborsClassifier(n\_neighbors=k) \\
         est.fit(train_data, train_labels)
         test_data = classification_problem[0][test_indices]
         test\_labels = classification\_problem[1][test\_indices]
         current_acc += metrics.accuracy_score(test_labels, est.predict(test_data))
      accuracy.append(current_acc / 5)
   return accuracy
```

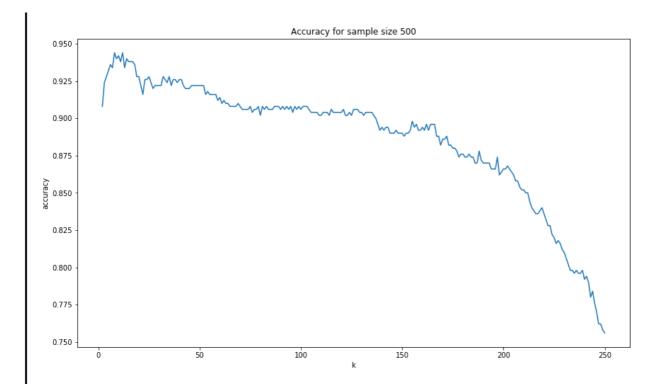
```
In [86]:
for size in [100, 200, 500, 1000]:
   plt.figure(figsize = (14, 8))
   k_max = size / 2
   accuracy = np.array(get_accuracies(size, k_max))
   plt.plot(np.array(range(2, k_max+1)), accuracy)
   plt.xlabel('k')
   plt.ylabel('accuracy')
   plt.title('Accuracy for sample size {}'.format(size))
   print "Максимум достигается при k = {}.".format(np.argmax(accuracy))
```



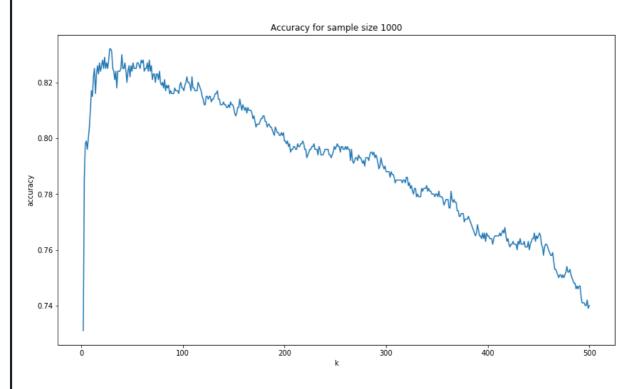
Максимум достигается при k = 2.



Максимум достигается при k = 8.



Максимум достигается при k = 6.



Максимум достигается при k = 26.

Таким образом, оптимальное значение количества соседей различно при различных размерах выборки, но для размеров, близких к рассмотренным, лучше брать чётное порядка sample\_size / 50.

Наивный байесовский классификатор

```
In [24]:
from sklearn import datasets
from sklearn.model_selection import cross_val_score as cvs
from sklearn.naive_bayes import BernoulliNB, MultinomialNB, GaussianNB
import numpy as np
%matplotlib inline
In [15]:
digits = datasets.load_digits()
# в этот момент я обновила sklearn, nomomy что breast_cancer в версии 0.15 нет
cancer = datasets.load_breast_cancer()
In [16]:
digits.data[:2]
Out[16]:
 array([[ 0., 0., 5., 13., 9., 1., 0., 0., 0., 0., 13.,
       15., 10., 15., 5., 0., 0., 3., 15., 2., 0., 11.,
        8., 0., 0., 4., 12., 0., 0., 8., 8., 0., 0.,
        5., 8., 0., 0., 9., 8., 0., 0., 4., 11., 0.,
        1., 12., 7., 0., 0., 2., 14., 5., 10., 12., 0.,
        0., 0., 0., 6., 13., 10., 0., 0., 0.],
     [ 0., 0., 0., 12., 13., 5., 0., 0., 0., 0., 0.,
       11., 16., 9., 0., 0., 0., 3., 15., 16., 6.,
        0., 0., 0., 7., 15., 16., 16., 2., 0., 0., 0.,
        0., 1., 16., 16., 3., 0., 0., 0., 0., 1., 16.,
       16., 6., 0., 0., 0., 1., 16., 16., 6., 0.,
        0., 0., 0., 11., 16., 10., 0., 0.]])
Признаки - нагуральные числа.
In [17]:
cancer.data[:2]
Out[17]:
 array([[ 1.79900000e+01, 1.03800000e+01, 1.22800000e+02,
        1.00100000e+03, 1.18400000e-01, 2.77600000e-01,
        3.00100000e-01, 1.47100000e-01, 2.41900000e-01,
        7.87100000e-02, 1.09500000e+00, 9.05300000e-01,
        8.58900000e+00, 1.53400000e+02, 6.39900000e-03,
        4.90400000e-02, 5.37300000e-02, 1.58700000e-02,
        3.00300000e-02, 6.19300000e-03, 2.53800000e+01,
        1.73300000e+01, 1.84600000e+02, 2.01900000e+03,
        1.62200000e-01, 6.65600000e-01, 7.11900000e-01,
        2.65400000e-01, 4.60100000e-01, 1.18900000e-01],
      [ 2.05700000e+01, 1.77700000e+01, 1.32900000e+02,
        1.32600000e+03, 8.47400000e-02, 7.86400000e-02,
        8.69000000e-02, 7.01700000e-02, 1.81200000e-01,
        5.66700000e-02, 5.43500000e-01, 7.33900000e-01,
        3.39800000e+00, 7.40800000e+01, 5.22500000e-03,
        1.30800000e-02, 1.86000000e-02, 1.34000000e-02,
        1.38900000e-02, 3.53200000e-03, 2.49900000e+01,
        2.34100000e+01, 1.58800000e+02, 1.95600000e+03,
        1.23800000e-01, 1.86600000e-01, 2.41600000e-01,
        1.86000000e-01, 2.75000000e-01, 8.90200000e-02]])
```

Признаки вещественные положительные.

```
clfB = BernoulliNB()
clfM = MultinomialNB()
clfG = GaussianNB()
for clf, clf_name in zip([clfB, clfM, clfG], ["Bernoulli", "Multinomial", "Gaussian"]):
    for dataset, ds_name in zip([digits, cancer], ["digits", "breast cancer"]):
```

for dataset, ds\_name in zip([digits, cancer], ["digits", "breast cancer"]):

print "{} for {}: {:.3}".format(clf\_name, ds\_name, np.mean(cvs(
clf, dataset.data, dataset.target)))

Bernoulli for digits: 0.826 Bernoulli for breast cancer: 0.627 Multinomial for digits: 0.871 Multinomial for breast cancer: 0.895

Gaussian for digits: 0.819 Gaussian for breast cancer: 0.937

Бернуллиевский классификатор предназначен для работы с бинарными признаками, поэтому неудивительно, что он так плохо работает с вещественными значениями и лучше, но не слишюм хорошо - с натуральными.

Итого лучшее качество для классификации цифр показал мультиномиальный наивный байесовский классификатор, для диагнозирования рака - гауссовский. Верно утверждение d - "На вещественных признаках лучше всего сработало нормальное распределение"; мультиномиальное распределение показало себя на выборке с целыми неотрицательными значениями признаков лучше остальных, но хуже, чем на выборке с вещественными значениями признаков, поэтому в зависимости от вложенного смысла утверждение с получается верно или неверно.

## Метрики в задаче регрессии

In [50]:

from scipy.stats import norm, uniform from scipy.optimize import minimize

```
In [66]:

sigma_2 = 0.2

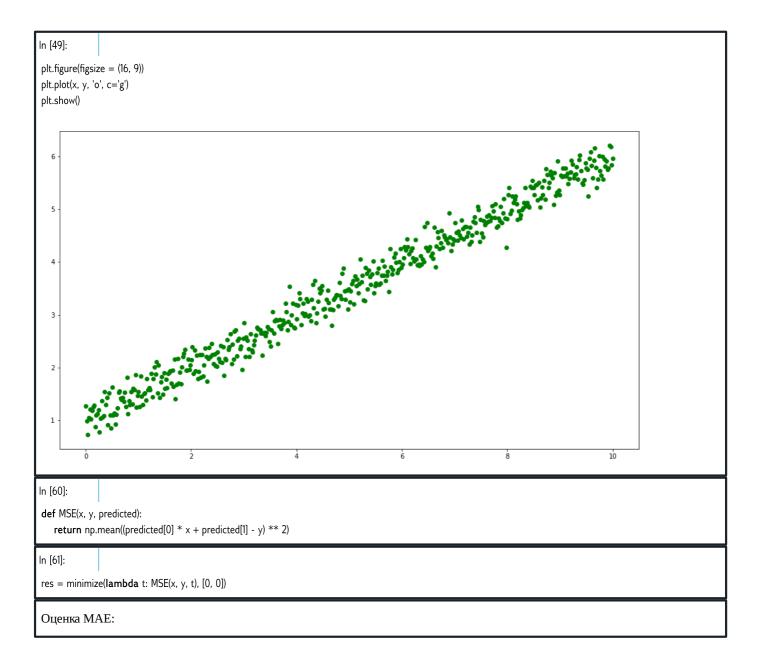
size = 500

start = 0.

end = 10.
```

In [44]:

```
x = np.linspace(start, end, size)
y = 0.5 * x + 1 + norm(0, sigma_2).rvs(size=size)
```



```
In [64]:
plt.figure(figsize = (16, 9))
plt.plot(x, y, 'o', c='g')
plt.plot(x, res.x[0] * x + res.x[1], lw=5)
plt.show()
Добавим выбросы:
In [67]:
noise_size = 75
y_noisy = np.concatenate((y, np.array([-1] * noise_size) +
                     norm(0, sigma_2).rvs(size=noise_size)))
x_noisy = np.concatenate((x, np.random.uniform(start, end, size=noise_size)))
In [69]:
```

**def** MAE(x, y, predicted):

In [72]:

**return** np.mean(np.abs(predicted[0] \* x + predicted[1] - y))

res\_mse = minimize(lambda t: MSE(x\_noisy, y\_noisy, t), [0, 0]).x res\_mae = minimize(lambda t: MAE(x\_noisy, y\_noisy, t), [0, 0]).x